

DEEP LEARNING · ADVANCED MODELS & METHODS

Imparare a vedere senza etichette

Track 11 — Masked Autoencoders for Image Representation Learning

Giovanni Torrìsi · Gruppo G21

github.com/GiovanniTorrìsi28/Masked-Autoencoders-for-Image-Representation-Learning


L'etichettatura è il collo di bottiglia della visione

Annotare milioni di immagini è **costoso e lento**.

Domanda: un Vision Transformer può imparare rappresentazioni utili *prima* di vedere una sola etichetta?

Idea (self-supervised): nascondi gran parte dell'immagine e chiedi al modello di **ricostruirla**.

ImageNet100 · 100 classi · ~130K
train · 5K val



Mascheriamo il 75% delle patch: resta visibile solo 1 patch su 4.

Il MAE ricostruisce il 75% nascosto da un quarto di immagine

1 · Masking

Immagine → 196 patch
16×16.

Si nasconde il **75%** (147 patch).

2 · Encoder ViT-Base

Vede solo le 49 patch
visibili.

~3× più leggero ed
efficiente.

3 · Decoder leggero

Reinserisce i *mask token* e
ricostruisce tutte le patch.

Loss: errore quadratico (MSE) sui pixel, calcolato **solo sulle patch mascherate** e normalizzato per patch → l'encoder è forzato a imparare la *struttura*, non i colori medi.

Una pipeline, due confronti equi

Pre-training MAE

500 epoche · 130K immagini · **nessuna etichetta**

↓ encoder pre-addestrato

A) Linear Probe

Encoder **congelato** + un solo layer lineare (768→100).

B) Baseline ViT supervisionato

Stesso ViT addestrato **da zero** con le etichette.

Studio data-efficiency

Ripetiamo A e B con solo il **10%** e **20%** delle etichette.

Subset stratificato (seed 42): A e B usano **le stesse immagini** → confronto onesto.

Scelte chiave del progetto

Architettura

- **ViT-Base/16** · ~86M parametri
- Patch 16×16 → 196 token
- Pos-embed sinusoidali 2D (fissi)
- Decoder: 512 dim · 8 layer

Training

- **Mask ratio 0.75**
- Loss su **pixel normalizzati**
- AdamW + cosine schedule
- No color-jitter nel pre-training


Tre *trick* chiave del paper MAE riprodotti: **masking alto** · **encoder asimmetrico** · **target normalizzati per patch**.

Quasi alla pari col supervisionato — senza etichette

Modello	Top-1	Top-5
ViT Superv.	72.9	88.6
MAE + LP	71.0	91.0


Solo **-1.9 pp** in Top-1.

In **Top-5 il MAE supera** il supervisionato (+2.4 pp): la classe giusta è quasi sempre tra le prime 5.



Dataset completo (100%) · l'encoder MAE struttura lo spazio delle feature **senza mai vedere un'etichetta** nel pre-training.

Con poche etichette, il pre-training cambia tutto



Al 10% dei dati:

63.1%


MAE + Linear Probe

8.3%

ViT Supervisionato


Il ViT da zero **collassa** (best epoch = 2): 86M parametri non si addestrano con ~130 img/classe.

Cosa impara — e dove sbaglia



Originale · Mascherato 75% · Ricostruzione

MAE vince sulle texture complesse — invertebrati e animali acquatici, dove ricostruire i pixel forza pattern fini:



Failure case comuni a tutti i modelli: classi *fine-grained* quasi identiche (17 specie di serpenti, anfibi).

Il pre-training MAE rende le rappresentazioni quasi indipendenti dalle etichette

-1.9 pp con dati pieni...

+54.8 pp quando le etichette scarseggiano.

Takeaway

- Self-supervised = robustezza in regime di poche etichette
- ViT senza bias induttivi ha bisogno di dati
 - pre-training
- Top-5 superiore → feature semanticamente strutturate

Iperparametri

	MAE pre-train	Supervisionato	Linear Probe
Epoche	500	200	200
Optimizer	AdamW	AdamW	AdamW
Learning rate	7.5e-5	1e-3	1e-2
Weight decay	0.05	0.05	0.0
Schedule	cosine	cosine	cosine
Batch size	128	128	128
Note	$\beta=(0.9,0.95)$ · clip 1.0	label smooth 0.1	encoder congelato

Tutti i risultati

Modello	Dati	Top-1	Top-5	Val loss
ViT Supervisionato	100%	72.94	88.62	1.313
MAE + Linear Probe	100%	71.02	91.04	1.091
ViT Supervisionato	20%	11.66	31.88	3.836
MAE + Linear Probe	20%	66.62	88.48	1.280
ViT Supervisionato	10%	8.30	25.92	3.999
MAE + Linear Probe	10%	63.12	86.90	1.425

Architettura: ViT-Base/16 (~86M param) · decoder 512 dim / 8 layer / 16 head · pos-embed sinusoidali 2D · valutazione su 5.000 immagini di validation.

Limiti e lavoro futuro

Limiti riconosciuti

- Pre-training **500 ep** (vs 1600 del paper)
- **ImageNet100**, non ImageNet-1K
- Solo frazioni 10% / 20% testate

Prossimi passi

- **Ablation** del mask ratio (25–90%)
- Confronto con metodi **contrastivi** (SimCLR, MoCo)
- **Full fine-tuning** dell'encoder MAE