

DEEP LEARNING · ADVANCED MODELS & METHODS

Imparare nascondendo

Track 11 — Masked Autoencoders for Image Representation Learning

Giovanni Torrìsi · Gruppo G21

github.com/GiovanniTorrìsi28/Masked-Autoencoders-for-Image-Representation-Learning


L'etichettatura è il collo di bottiglia della Computer Vision

Annotare milioni di immagini è **costoso e lento**.

Domanda: un Vision Transformer può imparare rappresentazioni utili *prima* di vedere una sola etichetta?

Idea (self-supervised): nascondi gran parte dell'immagine e chiedi al modello di **ricostruirla**.

ImageNet100 · 100 classi · ~130K
train · 5K val



Mascheriamo il 75% delle patch: resta visibile solo 1 patch su 4.

Il MAE ricostruisce il 75% nascosto da un quarto di immagine

1 · Masking

Immagine → 196 patch
16×16.

Si nasconde il **75%** (147 patch).

2 · Encoder ViT-Base

Vede **solo le 49 patch visibili.**

~3× più leggero ed efficiente.

3 · Decoder leggero

Reinserisce i *mask token* e **ricostruisce tutte** le patch.

Loss: errore quadratico (MSE) sui pixel, calcolato **solo sulle patch mascherate** e normalizzato per patch → l'encoder è forzato a imparare la *struttura*, non i colori medi.

Una pipeline, due confronti equi

Pre-training MAE

500 epoche · 130K immagini · **nessuna etichetta**

↓ encoder pre-addestrato

A) Linear Probe

Encoder **congelato** + un solo layer lineare (768→100).

B) Baseline ViT supervisionato

Stesso ViT addestrato **da zero** con le etichette.

Studio data-efficiency

Ripetiamo A e B con solo il **10%** e **20%** delle etichette.

Subset stratificato (seed 42): A e B usano **le stesse immagini** → confronto onesto.

Scelte chiave del progetto

Architettura

- **ViT-Base/16** · ~86M parametri
- Patch 16×16 → 196 token
- Pos-embed sinusoidali 2D (fissi)
- Decoder: 512 dim · 8 layer

Training

- **Mask ratio 0.75**
- Loss su **pixel normalizzati**
- AdamW + cosine schedule
- No color-jitter nel pre-training


Tre *trick* chiave del paper MAE riprodotti: **masking alto** · **encoder asimmetrico** · **target normalizzati per patch**.

Quasi alla pari col supervisionato — senza etichette


Dataset completo (100%)

Solo **-1.9 pp** in Top-1.

In **Top-5 il MAE supera** il supervisionato (+2.4 pp): la classe giusta è quasi sempre tra le prime 5.



Con poche etichette, il pre-training cambia tutto



Al 10% dei dati:

63.1%

MAE + Linear Probe


8.3%

ViT Supervisionato


Il ViT da zero **collassa** (best epoch = 2): 86M parametri non si addestrano con ~130 img/classe.

Cosa impara — e dove sbaglia

MAE vince al 10% dei dati — classi con texture caratteristica



Failure case — difficili per tutti (classi *fine-grained*)



Il pre-training MAE rende le rappresentazioni quasi indipendenti dalle etichette

-1.9 pp con dati pieni...

+54.8 pp quando le etichette scarseggiano.

Takeaway

- Self-supervised = robustezza in regime di poche etichette
- ViT senza bias induttivi ha bisogno di dati
 - pre-training
- Top-5 superiore → feature semanticamente strutturate

Limiti e lavoro futuro

Limiti riconosciuti

- Pre-training **500 ep** (vs 1600 del paper)
- **ImageNet100**, non ImageNet-1K
- Solo frazioni 10% / 20% testate

Prossimi passi

- **Ablation** del mask ratio (25–90%)
- Confronto con metodi **contrastivi** (SimCLR, MoCo)
- **Full fine-tuning** dell'encoder MAE